

Projet d'apprentissage statistique

MMD et un algorithme rapide pour un cas spécifique

LU Pengcheng ; WANG Lecheng ; ZHANG Chen

November 2024

1 Introduction de la MMD

1.1 Définition de la Discrépance Moyenne Maximale

Les tests à deux échantillons jouent un rôle important dans de nombreux domaines scientifiques et commerciaux. Par exemple, les chercheurs peuvent utiliser ces tests pour évaluer les effets d'un traitement entre les participants recevant un placebo et ceux recevant le véritable médicament, déterminant ainsi l'efficacité du médicament. La méthode de test a été largement étudiée dans la littérature statistique, en particulier dans le cas univarié.

Les tests à deux échantillons sont essentiellement un type de test d'hypothèse qui peut être formulé comme le problème suivant :

Problème 1 Soient x et y des variables aléatoires définies sur un espace topologique X , avec des mesures de probabilité de Borel respectives p et q . Étant donné les observations $X := \{x_1, \dots, x_m\}$ et $Y := \{y_1, \dots, y_n\}$, indépendamment et identiquement distribuées (i.i.d.) selon p et q , respectivement, peut-on décider si $p = q$?

— **Hypothèse 0** (H_0) : $p = q$.

— **Hypothèse 1** (H_1) : $p \neq q$.

Pour résoudre ce problème, de nombreuses méthodes de test d'hypothèse ont été proposées, y compris le test-t, le test du χ^2 , le test F et les tests non paramétriques tels que le test des rangs signés de Wilcoxon. Le choix de la méthode dépend de la distribution de l'échantillon. Typiquement, les tests paramétriques nécessitent une connaissance préalable du type de distribution spécifique des échantillons. Si aucune information sur la distribution de l'échantillon n'est disponible, les tests non paramétriques seront notre approche. Le test de Discrépance Moyenne Maximale (MMD) est l'un des tests non paramétriques les plus largement utilisés. Pendant le test, nous trouvons une fonction f bien comportée (par exemple, lisse) et calculons $E_p(f(x))$ et $E_q(f(y))$. Nous souhaitons choisir une fonction dans un ensemble $\mathcal{F}$, qui satisfait : $f \in \mathcal{C}(\mathcal{X})$, où $\mathcal{C}(\mathcal{X})$ est l'espace des fonctions continues bornées sur $\mathcal{X}$.

Naturellement, nous définissons la MMD sous la forme suivant :

Définition 1 Soit $\mathcal{F}$ une classe de fonctions $f : \mathcal{X} \rightarrow \mathbb{R}$, et soient p, q, x, y, X, Y définis comme ci-dessus. Nous définissons la discrépance moyenne maximale (MMD) comme suit :

$$\text{MMD}[\mathcal{F}, p, q] := \sup_{f \in \mathcal{F}} (E_p[f(x)] - E_q[f(y)]).$$

En principe, $\mathcal{C}(\mathcal{X})$ peut nous permettre de déterminer si $p = q$, mais il n'est pas pratique de travailler avec une classe de fonctions aussi riche, en particulier lorsque les échantillons sont finis. Afin de résoudre ce problème, nous avons besoin d'un espace fonctionnel plus restreint pour mesurer la disparité entre les différentes distributions.

1.2 MMD dans RKHS

Dans cette section, nous utiliserons l'espace de Hilbert à noyau reproduisant (RKHS) comme une alternative à l'espace des fonctions continues. Nous commencerons par introduire quelques définitions et

propriétés fondamentales associées, puis simplifierons l'expression de la MMD en exploitant ces propriétés.

Nous introduisons d'abord sans preuve quelques propriétés courantes concernant le RKHS, rappelons la définition d'un noyau. Une fonction $k : \mathcal{X}^2 \rightarrow \mathbb{R}$ est un noyau si et seulement s'il est semi-défini positif.

Définition 2

$\mathcal{H} \subset \mathcal{R}^{\mathcal{X}}$ est un espace de Hilbert. $\mathcal{H}$ est un RKHS avec noyau k si et seulement si :

$$\forall x \in \mathcal{X}, k(x, \cdot) \in \mathcal{H} \quad \text{et} \quad \forall f \in \mathcal{H} : f(x) = \langle f, k(x, \cdot) \rangle_{\mathcal{H}}.$$

Propriété 3 (Théorème de représentation de Riesz (Reed and Simon (1980))) Il existe un mapping caractéristique $\phi(x)$ de $\mathcal{X}$ vers $\mathbb{R}$ tel que $f(x) = \langle f, \phi(x) \rangle_{\mathcal{H}}$.

Propriété 4 (Steinwart and Christmann (2008)) Le mapping caractéristique prend la forme canonique $\phi(x) = k(x, \cdot)$, où $k(x_1, x_2) : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ est défini positif, et la notation $k(x, \cdot)$ indique que le noyau a un argument fixé à x , et l'autre est libre.

Notons en particulier que $\langle \phi(x), \phi(y) \rangle_{\mathcal{H}} = k(x, y)$.

Unicité : Un noyau défini positif donné détermine de manière unique le RKHS, et inversement, chaque RKHS possède un noyau reproduisant unique qui satisfait :

— **Propriété de reproduction :**

$$f(x) = \langle f, k(x, \cdot) \rangle_{\mathcal{H}}$$

où $k(x, \cdot)$ est la fonction noyau centrée en x .

— **Symétrie :**

$$k(x, y) = k(y, x).$$

— **Définition positive :** Pour tout ensemble fini $\{x_1, x_2, \dots, x_n\} \subset \mathcal{X}$ et coefficients réels $\{c_1, c_2, \dots, c_n\}$, on a :

$$\sum_{i=1}^n \sum_{j=1}^n c_i c_j k(x_i, x_j) \geq 0.$$

Un noyau défini positif $k(x, y)$ définit de manière unique un RKHS en tant que "générateur" de l'espace produit scalaire et des propriétés de reproduction. Inversement, chaque RKHS possède un noyau unique associé.

Nous faisons référence à l'élément dans le RKHS correspondant à la distribution p comme l'embedding moyen de p .

Définition 5 : Nous appelons un élément u_p l'embedding moyen de p si u_p satisfait :

$$E_x[f(x)] = \langle f, u_p \rangle_{\mathcal{H}}, \quad \text{pour tout } f \in \mathcal{H}.$$

Lemme 6 Si $k(\cdot, \cdot)$ est mesurable et $\mathbb{E}_x \sqrt{k(x, x)} < \infty$, alors $\mu_p \in \mathcal{H}$.

Preuve : L'opérateur linéaire $T_p f = \mathbb{E}_x f$ pour tout $f \in \mathcal{F}$ est borné sous l'hypothèse suivante, car :

$$|T_p f| = |\mathbb{E}_x f| \leq \mathbb{E}_x |f| = \mathbb{E}_x |\langle f, \phi(x) \rangle_{\mathcal{H}}| \leq \mathbb{E}_x \left(\sqrt{k(x, x)} \|f\|_{\mathcal{H}} \right).$$

Ainsi, par le théorème du représentant de Riesz, il existe un $\mu_p \in \mathcal{H}$ tel que $T_p f = \langle f, \mu_p \rangle_{\mathcal{H}}$. Si nous posons $f = \phi(t) = k(t, \cdot)$, nous obtenons $\mu_p(t) = \langle \mu_p, k(t, \cdot) \rangle_{\mathcal{H}} = \mathbb{E}_x k(t, x)$. En d'autres termes, l'encodage moyen de la distribution p est l'espérance sous p de la carte caractéristique canonique.

Il est clair que la norme de f dans $\mathcal{H}$ (écrite avec une double barre verticale) peut influencer les résultats. Comme nous souhaitons calculer $\mathbb{E}_x[f(x)] - \mathbb{E}_y[f(y)]$, nous pouvons contraindre la norme de f à 1. Maintenant, nous pouvons officiellement définir la MMD que nous utiliserons dans la section ci-dessous.

Lemme 7 Supposons que la condition dans le Lemme 3 pour l'existence des encodages moyens μ_p et μ_q soit satisfaite. Alors,

$$\text{MMD}^2[\mathcal{F}, p, q] = \|\mu_p - \mu_q\|_{\mathcal{H}}^2.$$

Preuve :

$$\begin{aligned} \text{MMD}^2[\mathcal{F}, p, q] &= \left[\sup_{\|f\|_{\mathcal{H}} \leq 1} (\mathbb{E}_x[f(x)] - \mathbb{E}_y[f(y)]) \right]^2 \\ &= \left[\sup_{\|f\|_{\mathcal{H}} \leq 1} \langle \mu_p - \mu_q, f \rangle_{\mathcal{H}} \right]^2 \\ &= \|\mu_p - \mu_q\|_{\mathcal{H}}^2. \end{aligned}$$

Maintenant, nous espérons que la MMD puisse jouer un rôle en tant que métrique, ce qui signifie que $\text{MMD}(\mathcal{F}, p, q) = 0$ est équivalent à $p = q$. Pour ce faire, nous souhaitons que l'opérateur d'encodage soit injectif. Cela n'est pas trivial : par exemple, un RKHS polynomial de degré deux ne peut pas distinguer entre des distributions ayant la même moyenne et la même variance. Cependant, la MMD est une métrique lorsque $\mathcal{H}$ est un RKHS universel, défini sur un espace métrique compact X . L'universalité exige que $k(\cdot, \cdot)$ soit continue et que $\mathcal{H}$ soit dense dans $C(X)$ par rapport à la norme L_{∞} . Steinwart (2001) a démontré que les RKHSs de Gaussien et de Laplace sont universelles.

Théorème 8 Soit $\mathcal{F}$ la boule unité dans un RKHS universel $\mathcal{H}$, défini sur l'espace métrique compact X , avec un noyau continu associé $k(\cdot, \cdot)$. Alors, $\text{MMD}[\mathcal{F}, p, q] = 0$ si et seulement si $p = q$.

Preuve : Tout d'abord, il est évident que $p = q$ implique que $\text{MMD}[\mathcal{F}, p, q]$ est nul. Nous prouvons maintenant la réciproque. Par l'universalité de $\mathcal{H}$, pour tout $\epsilon > 0$ donné et $f \in C(X)$, il existe $g \in \mathcal{H}$ tel que

$$\|f - g\|_{\infty} \leq \epsilon.$$

Nous effectuons ensuite l'expansion suivante :

$$|\mathbb{E}_x[f(x)] - \mathbb{E}_y[f(y)]| \leq |\mathbb{E}_x[f(x)] - \mathbb{E}_x[g(x)]| + |\mathbb{E}_x[g(x)] - \mathbb{E}_y[g(y)]| + |\mathbb{E}_y[g(y)] - \mathbb{E}_y[f(y)]|.$$

Les premier et troisième termes vérifient :

$$|\mathbb{E}_x[f(x)] - \mathbb{E}_x[g(x)]| \leq \mathbb{E}_x|f(x) - g(x)| \leq \epsilon.$$

Ensuite, on écrit :

$$\mathbb{E}_x[g(x)] - \mathbb{E}_y[g(y)] = \langle g, \mu_p - \mu_q \rangle_{\mathcal{H}} = 0,$$

car $\text{MMD}[\mathcal{F}, p, q] = 0$ implique $\mu_p = \mu_q$. Ainsi :

$$|\mathbb{E}_x[f(x)] - \mathbb{E}_y[f(y)]| \leq 2\epsilon,$$

pour tout $f \in C(X)$ et $\epsilon > 0$, ce qui implique $p = q$.

Bien que notre résultat établisse que l'application μ_p est injective pour des noyaux universels sur des domaines compacts, ce résultat peut également être démontré dans des cas plus généraux. Fukumizu et al. ont établi que les noyaux gaussiens et de Laplace sont caractéristiques sur $\mathbb{R}^d$, et que la MMD associée est une métrique sur les distributions pour ce domaine.

Étant donné que nous sommes dans un RKHS, nous pouvons facilement obtenir la MMD au carré, $\|\mu_p - \mu_q\|_{\mathcal{H}}^2$, en termes de fonctions noyaux, ainsi qu'une estimation sans biais correspondante sur un échantillon fini.

Lemme 9 Soient x et x' des variables aléatoires indépendantes suivant la distribution p , et y et y' des variables aléatoires indépendantes suivant la distribution q . La MMD au carré pour la population est donnée par :

$$\text{MMD}^2[\mathcal{F}, p, q] = \mathbb{E}_{xx'}[k(x, x')] - 2\mathbb{E}_{xy}[k(x, y)] + \mathbb{E}_{yy'}[k(y, y')],$$

où x' est une copie indépendante de x avec la même distribution, et y' est une copie indépendante de y .

Une estimation empirique sans biais(unbiased) est une somme de deux U -statistiques et d'une moyenne d'échantillon :

$$\text{MMD}_u^2[\mathcal{F}, X, Y] = \frac{1}{m(m-1)} \sum_{i \neq j}^m k(x_i, x_j) + \frac{1}{n(n-1)} \sum_{i \neq j}^n k(y_i, y_j) - \frac{2}{mn} \sum_{i=1}^m \sum_{j=1}^n k(x_i, y_j). \quad (1)$$

Preuve : En partant de l'expression de $\text{MMD}^2[\mathcal{F}, p, q]$ dans le Lemme 7, et prend propriété 3 et 4 :

$$\begin{aligned} \text{MMD}^2[\mathcal{F}, p, q] &= \|\mu_p - \mu_q\|_{\mathcal{H}}^2 = \langle \mu_p, \mu_p \rangle_{\mathcal{H}} + \langle \mu_q, \mu_q \rangle_{\mathcal{H}} - 2\langle \mu_p, \mu_q \rangle_{\mathcal{H}} \\ &= \mathbb{E}_{xx'}[\langle \phi(x), \phi(x') \rangle_{\mathcal{H}}] + \mathbb{E}_{yy'}[\langle \phi(y), \phi(y') \rangle_{\mathcal{H}}] - 2\mathbb{E}_{xy}[\langle \phi(x), \phi(y) \rangle_{\mathcal{H}}]. \end{aligned}$$

La preuve est complétée en appliquant $\langle \phi(x), \phi(x') \rangle_{\mathcal{H}} = k(x, x')$. Les estimations empiriques sont obtenues directement en remplaçant les espérances de la population par leurs équivalents U -statistiques et moyennes d'échantillon. Cette statistique est sans biais conformément à Serfling (1980, Chapitre 5).

Notons que MMD_u^2 peut être négative, car il s'agit d'un estimateur sans biais de $(\text{MMD}[\mathcal{F}, p, q])^2$. Les seuls termes manquants pour garantir la non-négativité sont $h(z_i, z_i)$, qui ont été supprimés pour éliminer les corrélations spurieuses entre les observations. Par conséquent, nous avons la borne suivante :

$$\text{MMD}_u^2 + \frac{1}{m(m-1)} \sum_{i=1}^m (k(x_i, x_i) + k(y_i, y_i) - 2k(x_i, y_i)) \geq 0.$$

Définition 10 La statistique biaisée peut être facilement calculée en suivant le raisonnement ci-dessus. En substituant les estimations empiriques $\mu_X := \frac{1}{m} \sum_{i=1}^m \phi(x_i)$ et $\mu_Y := \frac{1}{n} \sum_{j=1}^n \phi(y_j)$ des moyennes dans l'espace de caractéristiques, basées respectivement sur les échantillons X et Y , nous obtenons :

$$\text{MMD}_b[\mathcal{F}, X, Y] = \left[\frac{1}{m^2} \sum_{i,j=1}^m k(x_i, x_j) - \frac{2}{mn} \sum_{i=1}^m \sum_{j=1}^n k(x_i, y_j) + \frac{1}{n^2} \sum_{i,j=1}^n k(y_i, y_j) \right]^{\frac{1}{2}}.$$

2 Sélection de noyau pour RKHS

La sélection du noyau est cruciale pour le test MMD. Même pour un ensemble de données identique, la sélection d'un noyau différent peut produire des valeurs MMD différentes. Nous présentons deux types de noyaux : le noyau de Laplace (ou gaussien) et le noyau de distance énergétique.

Noyau de Laplace

Définition 11 L'expression du noyau de Laplace est donnée par :

$$k(x, y) = \exp\left(-\frac{|x - y|}{\gamma}\right),$$

où $\gamma > 0$ est un hyperparamètre contrôlant la vitesse d'atténuation des distances.

Le noyau de Laplace présente les caractéristiques suivantes :

- Résistant au bruit : insensible aux valeurs aberrantes et au bruit, ce qui est efficace pour identifier des ensembles de données présentant des biais importants.
- Sensibilité aux caractéristiques locales : idéal pour capturer les subtilités des distributions, comme dans la reconnaissance d'images.
- Performances élevées en haute dimension : efficace pour analyser des données non linéaires en haute dimension, par exemple en biologie ou en finance.

Noyau de distance énergétique

Définition 12 Le noyau de distance énergétique est défini par :

$$k(x, y) = |x - y|.$$

Les caractéristiques du noyau de distance énergétique incluent :

- Identifie principalement les différences dans les statistiques globales, comme la moyenne et la variance.
- Simple à utiliser, car il ne nécessite pas de sélection d'hyperparamètres.
- Interprétation claire, car basé sur la distance euclidienne.
- Efficace pour des données de dimensions faibles ou modérées ($p \leq 100$).

Choix des hyperparamètres pour les noyaux

Comment choisir les hyperparamètres des noyaux (non limité aux noyaux Laplace ou Gauss) reste un problème à résoudre. Une méthode couramment utilisée est l'approche basée sur la médiane. Pour un ensemble unidimensionnel d'échantillons $\{z_1, z_2, \dots, z_n\}$, on calcule toutes les différences absolues possibles $|z_i - z_j|$ (où $i < j$).

On prend la médiane h de ces différences absolues, puis on définit le paramètre du noyau comme suit :

$$\beta = \frac{1}{h}.$$

Si toutes les distances entre échantillons doivent être calculées par paires pour obtenir la médiane, alors la complexité de calcul est $O(n^2)$. Une alternative consiste à utiliser un algorithme de sélection en temps linéaire (*Linear Time Selection Algorithm*), dont la complexité est $O(n \log n)$.

Étapes de l'algorithme

1. **Mise en ordre des données** : Tout d'abord, mettons les données en ordres $\{z_1, z_2, \dots, z_n\}$ pour obtenir $\{z_{(1)}, z_{(2)}, \dots, z_{(n)}\}$.
2. **Calcul des différences** : Calculez $z_{(i)} - z_{(i-1)}$ pour chaque i .
3. **Recherche de la médiane via une méthode de dichotomie** :
 - (a) Sélectionnez aléatoirement une différence candidate d .
 - (b) Vérifiez combien de paires (i, j) satisfont $|z_{(i)} - z_{(j)}| \leq d$. Si le nombre de ces paires est supérieur à la moitié du total, alors la médiane se trouve dans l'intervalle des différences plus petites ; sinon, elle se trouve dans l'intervalle des différences plus grandes.

La complexité de chaque recherche dichotomique est $O(n)$.

Estimation du temps linéaire

Il est souhaitable d'obtenir des tests de complexité $O(n)$ qui ne sacrifient pas trop la puissance statistique. De plus, nous souhaitons obtenir des tests ayant des exigences de stockage de $O(1)$ pour le calcul des statistiques de test, afin de pouvoir appliquer ces tests à des flux de données.

Soit une série de variables aléatoires $\mathbf{X} = \{x_1, \dots, x_n\} \sim p$, iid, $\mathbf{Y} = \{y_1, \dots, y_n\} \sim q$, iid. **Notons :**

$$\mathcal{K} = \left\{ k : k = \sum_{u=1}^d \beta_u k_u, \quad \sum_{u=1}^d \beta_u = D, \quad \beta_u \geq 0, \quad \forall u \in \{1, \dots, d\} \right\} \quad (2)$$

L'estimation linéaire de $\eta_k(p, q)$ est définie comme suit :

Définition 13 Soit $n_2 := \lfloor n/2 \rfloor$, et définissons $h(z_1, z_2)$ comme dans le Lemme 9. L'estimateur

$$\text{MMD}_l^2[\mathcal{F}, X, Y] := \frac{1}{n_2} \sum_{i=1}^{n_2} h((x_{2i-1}, y_{2i-1}), (x_{2i}, y_{2i}))$$

peut être calculé en temps linéaire, et est un estimateur non biaisé de $\text{MMD}^2[\mathcal{F}, p, q]$.

Pour simplifier la notation, en supposant que n est pair,

$$\hat{\eta}_k = \frac{2}{n} \sum_{i=1}^{n/2} h_k(v_i),$$

où $v_i = [x_{2i-1}, x_{2i}, y_{2i-1}, y_{2i}]$ et $h_k(v_i) := k(x_{2i-1}, x_{2i}) + k(y_{2i-1}, y_{2i}) - k(x_{2i-1}, y_{2i-1}) - k(x_{2i}, y_{2i-1})$; cet arrangement des échantillons garantit que nous obtenons une espérance sur des variables indépendantes.

Puisque $\hat{\eta}_k$ est une moyenne directe de variables aléatoires indépendantes, sa distribution asymptotique est donnée par le théorème de la limite centrale (par exemple, [Serfling (1980) ,Section 1.9]).

Corollaire 14 Supposons $0 < E(k^2) < \infty$. Alors MMD_l^2 converge en distribution vers une gaussienne, selon

$$m^{1/2} (\text{MMD}_l^2 - \text{MMD}^2[\mathcal{F}, p, q]) \xrightarrow{D} \mathcal{N}(0, \sigma_l^2),$$

où

$$\sigma_l^2 = 2 \left[\mathbb{E}_{z, z'} h^2(z, z') - (\mathbb{E}_{z, z'} h(z, z'))^2 \right],$$

où l'on utilise l'abréviation $\mathbb{E}_{z, z'} := \mathbb{E}_{z, z' \sim p \otimes q}$.

D'après le corollaire 14, sous l'hypothèse $0 < E(h_k^2) < \infty$ (ce qui est vrai pour k continu et borné),

$$n^{1/2} (\hat{\eta}_k - \eta_k(p, q)) \xrightarrow{D} \mathcal{N}(0, 2\sigma_k^2),$$

où le facteur de deux apparaît car la moyenne est calculée sur $n/2$ termes, et

$$\sigma_k^2 = \mathbb{E}_v h_k^2(v) - [\mathbb{E}_v (h_k(v))]^2, \quad \eta_k(p, q) = \mathbb{E}_{x, x', y, y'} h_k(x, x', y, y') = \mathbb{E}_v h_k(v).$$

En utilisant le paramètre de noyau β , on a

$$\sigma_k^2 = \beta^T Q_k \beta$$

où $Q_k = \text{cov}(h)$. Alors un estimateur de variance est comme suit :

$$\hat{\sigma}_k^2 = \beta^\top \tilde{Q}_k \beta, \quad \text{where} \quad (\hat{Q}_k)_{uu'} = \frac{4}{n} \sum_{i=1}^{n/4} h_{\Delta, u}(w_i) h_{\Delta, u'}(w_i),$$

et $w_i := [v_{2i-1}, v_{2i}]$, $h_{\Delta, k}(w_i) := h_k(v_{2i-1}) - h_k(v_{2i})$.

Pour effectuer un test de double échantillon, nous devons déterminer la valeur critique du test. Selon la distribution asymptotique, lorsque l'hypothèse nulle H_0 est vraie, la statistique de MMD suit une distribution normale centrée de moyenne zéro. Par conséquent, au niveau de signification α , la valeur critique $t_{k,\alpha}$ peut s'écrire :

$$t_{k,\alpha} = \frac{\sigma_k \sqrt{2}}{\sqrt{n}} \Phi^{-1}(1 - \alpha)$$

où :

- Φ^{-1} est la fonction de répartition inverse de la loi normale standard ;
- α est le taux d'erreur de type I.

Si $\hat{\eta}_k$ dépasse cette valeur critique, nous rejetons l'hypothèse nulle H_0 et nous concluons que $p \neq q$.

Probabilité d'erreur de type II :

$$P(\hat{\eta}_k < t_{k,\alpha}) = \Phi \left(\Phi^{-1}(1 - \alpha) - \frac{\eta_k(p, q) \sqrt{n}}{\sigma_k \sqrt{2}} \right).$$

Par conséquent, avec l'augmentation de $\eta_k(p, q) \sigma_k^{-1}$, la probabilité d'erreur de type II diminue. Donc, le meilleur choix est :

$$k_* = \arg \sup_{k \in \mathcal{K}} \eta_k(p, q) \sigma_k^{-1},$$

Étant donné qu'en pratique nous ne pouvons pas obtenir $\eta_k(p, q)$ et σ_k , nous utilisons leurs estimations empiriques de training data set à la place. Alors on estime $t_{k_*, \alpha}$ par estimateur $t_{\hat{k}_*, \alpha}$, ici

$$\hat{k}_* = \arg \sup_{k \in \mathcal{K}} \hat{\eta}_k / \hat{\sigma}_{k,\lambda}$$

Nous définissons l'écart type régularisé $\hat{\sigma}_{k,\lambda}$:

$$\hat{\sigma}_{k,\lambda} = \sqrt{\beta^T \left(\hat{Q} + \lambda_m I \right) \beta} = \sqrt{\hat{\sigma}_k^2 + \lambda_m \|\beta\|^2}.$$

Justification de l'efficacité de la sélection :

Théorème 15 Soit $\mathcal{K}$ définie comme (2). Supposons $\sup_{k \in \mathcal{K}, x, y \in \mathcal{X}} |k(x, y)| < K$ et que σ_k est strictement positive. Alors si $\lambda_m = \Theta(m^{-1/3})$,

$$\left| \sup_{k \in \mathcal{K}} \hat{\eta}_k \hat{\sigma}_{k,\lambda}^{-1} - \sup_{k \in \mathcal{K}} \eta_k \sigma_k^{-1} \right| = O_P(m^{-1/3}), \quad \text{et} \quad \hat{k}_\lambda \xrightarrow{P} k_*.$$

Preuve : Rappelons la définition de $\mathcal{K}$ telle que $\|\beta\|_1 = D$ et que $\|\beta\|_2 \leq \|\beta\|_1$ et $\|\beta\|_1 \leq \sqrt{d} \|\beta\|_2$ [11, Problème 3 p. 278], par conséquent $\|\beta\|_2 \geq Dd^{-1/2}$. Commençons avec la majoration :

$$\begin{aligned} & \left| \sup_{k \in \mathcal{K}} \hat{\eta}_k \hat{\sigma}_{k,\lambda}^{-1} - \sup_{k \in \mathcal{K}} \eta_k \sigma_k^{-1} \right| \leq \sup_{k \in \mathcal{K}} \left| \hat{\eta}_k \hat{\sigma}_{k,\lambda}^{-1} - \eta_k \sigma_k^{-1} \right| \\ & \leq \sup_{k \in \mathcal{K}} \left| \hat{\eta}_k \hat{\sigma}_{k,\lambda}^{-1} - \hat{\eta}_k \sigma_k^{-1} \right| + \sup_{k \in \mathcal{K}} \left| \hat{\eta}_k \sigma_k^{-1} - \eta_k \sigma_k^{-1} \right| \\ & \leq \sup_{k \in \mathcal{K}} (\hat{\sigma}_{k,\lambda}^{-2} - \sigma_k^{-2})^{-1/2} |\hat{\eta}_k - \eta_k| + \sup_{k \in \mathcal{K}} \frac{\sigma_{k,\lambda} - \sigma_k}{\sigma_k} + \sup_{k \in \mathcal{K}} \frac{\eta_k}{\sigma_k} \\ & \leq \frac{C_1 \sqrt{d}}{D \sqrt{\lambda_m}} \sup_{k \in \mathcal{K}} |\hat{\eta}_k - \eta_k| + C_2 \sup_{k \in \mathcal{K}} |\sigma_{k,\lambda} - \sigma_k| + C_3 D^2 \lambda_m, \end{aligned}$$

où les constantes C_1, C_2, C_3 suivent des bornes sur σ_k et η_k . Le premier résultat du théorème suit de $\sup_{k \in \mathcal{K}} |\hat{\eta}_k - \eta_k| = O_P(m^{-1/2})$ et $\sup_{k \in \mathcal{K}} |\sigma_{k,\lambda} - \sigma_k| = O_P(m^{-1/2})$, qui sont prouvés en utilisant le Théorème de McDiarmid (McDiarmid (1989)) et les résultats de Bartlett and Mendelson (2002) .

Convergence de $\hat{k}_\lambda$ vers k_* . Pour $k \in \mathcal{K}$ définie en (2), cela est montré dans [Ramdas et al. \(2015\)](#) suivant que $\hat{k}_\lambda$ et k_* sont des optimiseurs uniques de $\hat{\eta}_k \hat{\sigma}_k^{-1}$ et $\eta_k \sigma_k^{-1}$ respectivement. Puisque $\sup_{k \in \mathcal{K}} \frac{\hat{\eta}_k}{\hat{\sigma}_{k,\lambda}} \xrightarrow{\mathbb{P}} \sup_{k \in \mathcal{K}} \frac{\eta_k}{\sigma_k}$, le résultat suit de ([van der Vaart and Wellner \(1996\)](#), Corollary 3.2.3(i)).

Ce théorème montre la convergence de $\sup_{k \in \mathcal{K}} \hat{\eta}_k (\hat{\sigma}_{k,\lambda})^{-1}$ vers $\sup_{k \in \mathcal{K}} \eta_k(p, q) \sigma_k^{-1}$, et de $\hat{k}_\lambda$ vers k_* pour un calendrier approprié de diminution de λ_m avec l'augmentation de m .

Nous voulons choisir le noyau optimal $k = \sum_{u=1}^d \hat{\beta}_u^* k_u \in \mathcal{K}$ qui maximise $\hat{\eta}_k / \hat{\sigma}_{k,\lambda}$. Nous effectuons cette optimisation sur les données d'entraînement, puis utilisons les paramètres résultants $\hat{\beta}^*$ pour construire un test d'hypothèse sur les données à tester (qui doivent être indépendantes des données d'entraînement et tirées des mêmes distributions p, q). Rappelons que $\hat{\eta}_k = \beta^\top \hat{\eta}$, et $\hat{\sigma}_{k,\lambda} = \sqrt{\beta^\top (\hat{Q} + \lambda_m I) \beta}$, où $\hat{Q}$ est une estimation empirique en temps linéaire de la matrice de covariance $\text{cov}(h)$.

Étant donné que l'objectif

$$\alpha(\beta; \hat{\eta}, \hat{Q}) := (\beta^\top \hat{\eta}) \left(\beta^\top (\hat{Q} + \lambda_m I) \beta \right)^{-1/2}$$

est une fonction homogène d'ordre zéro en β , nous pouvons omettre la contrainte $\|\beta\|_1 = D$, et poser

$$\hat{\beta}^* = \arg \max_{\beta \succeq 0} \alpha(\beta; \hat{\eta}, \hat{Q}).$$

En résolvant ce problème d'optimisation, nous pouvons obtenir la solution optimale k ([Gretton et al. \(2012\)](#), Section 4).

Le contenu ci-dessus présente une méthode de sélection de fonction noyau. Bien que cette méthode permette de contrôler efficacement l'erreur de type II, elle nécessite un coût de calcul supplémentaire. Bien entendu, cela ne constitue pas le point central de cet article. Par conséquent, dans cet article, nous choisissons d'utiliser une méthode heuristique basée sur la médiane pour sélectionner directement la fonction noyau. Bien que cette méthode heuristique ne permette parfois pas de choisir un noyau optimal ([Ramdas et al. \(2015\)](#)), elle donne de bons résultats dans la plupart des cas.

3 Algorithme : euMMD

3.1 euMMD

Pour compter efficacement MMD², nous proposons un algorithme euMMD. Pour tout $m \geq 1$,

Lemme 16 Soit un ensemble $\{z_1, z_2, \dots, z_m\} \subset \mathbb{R}$ et une fonction symétrique $f : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$, alors

$$\sum_{i=1}^m \sum_{j=1}^m f(z_i, z_j) = \sum_{i=1}^m \sum_{j=i}^m f(z_i, z_j).$$

La preuve peut être obtenue directement par la propriété de l'addition. On peut également considérer $f(z_i, z_j)$, $1 \leq i, j \leq m$ comme une matrice symétrique, où le côté gauche représente la somme de tous les éléments de la matrice triangulaire inférieure, y compris les éléments diagonaux, et le côté droit représente la somme de tous les éléments de la matrice triangulaire supérieure, y compris les éléments diagonaux. Ce lemme constitue une étape importante pour le résultat suivant, que l'on peut directement obtenir :

Lemme 17 Soit un ensemble $\{z_1, z_2, \dots, z_m\} \subset \mathbb{R}$ et une fonction symétrique $f : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$, alors

$$\sum_{i=1}^m \sum_{\substack{j=1 \\ j \neq i}}^m f(z_i, z_j) = 2 \sum_{i=1}^m \sum_{j=1}^{i-1} f(z_i, z_j).$$

Preuve : La preuve est immédiate :

$$\sum_{i=1}^m \sum_{\substack{j=1 \\ j \neq i}}^m f(z_i, z_j) = \sum_{i=1}^m \sum_{j=1}^{i-1} f(z_i, z_j) + \sum_{i=1}^m \sum_{j=i+1}^m f(z_i, z_j) = 2 \sum_{i=1}^m \sum_{j=1}^{i-1} f(z_i, z_j),$$

où la dernière égalité découle du Lemme 16.

D'après [Shawe-Taylor and Cristianini \(2004\)](#), toutes les fonctions de noyaux sont symétriques. Lemme 17 nous permet de récrire MMD^2 (unbiased) sous la forme suivant :

$$\text{MMD}^2(\mathbf{x}, \mathbf{y}) = 2(\alpha_1 T_1 + \alpha_2 T_2 + \alpha_3 T_3),$$

où

$$\begin{aligned} T_1 &= \sum_{i=1}^{n_1} \sum_{j=1}^{i-1} k(x_i, x_j), & \alpha_1 &= \frac{1}{n_1(n_1-1)}, \\ T_2 &= \sum_{p=1}^{n_2} \sum_{q=1}^{p-1} k(y_p, y_q), & \alpha_2 &= \frac{1}{n_2(n_2-1)}, \\ T_3 &= \sum_{i=1}^{n_1} \sum_{p=1}^{n_2} k(x_i, y_p), & \alpha_3 &= \frac{-1}{n_1 n_2} \end{aligned}$$

Pour le calcul des trois parties ci-dessus, cela peut être attribué au problème de sommation de trois matrices triangulaires inférieure, car $T_3 = T_4 - T_1 - T_2$ où T_4 est la somme de triangle inférieur de la matrice entière.

FIGURE 1 – Matrice de noyau d'ensemble $\{x_1, x_2, \dots, x_{n_1}, y_1, y_2, \dots, y_{n_2}\}$

Ainsi, une méthode rapide pour calculer une matrice triangulaire inférieure est cruciale. Le lemme suivant nous indique que l'ordre dans lequel les éléments sont additionnés n'a pas d'importance.

Lemme 18 Étant donné un ensemble $\{z_1, z_2, \dots, z_m\} \subset \mathbb{R}$, une fonction symétrique $f : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$, et une permutation $\sigma : \{1, 2, \dots, m\} \rightarrow \{1, 2, \dots, m\}$, alors :

$$\sum_{i=1}^m \sum_{j=1}^{i-1} f(z_i, z_j) = \sum_{i=1}^m \sum_{j=1}^{i-1} f(z_{\sigma(i)}, z_{\sigma(j)}). \quad (3)$$

En utilisant le Lemme 18, nous pouvons obtenir la Proposition suivante :

Proposition 19 Étant donné un ensemble d'observations $\{z_1, z_2, \dots, z_m\} \subset \mathbb{R}$, soit $z_{(i)}$ le i -ième plus petit élément de l'ensemble, de sorte que $z_{(1)} \leq z_{(2)} \leq \dots \leq z_{(m)}$. En utilisant le noyau de Laplace avec le paramètre $\beta > 0$, la quantité

$$S = \sum_{i=1}^m \sum_{j=1}^{i-1} k_{L,\beta}(z_i, z_j) = \sum_{i=1}^m \sum_{j=1}^{i-1} \exp(-\beta |z_{(i)} - z_{(j)}|),$$

peut être calculée récursivement en définissant $S = S_m$ et en utilisant les équations $S_1 = R_1 = 0$ et, pour $k \in \{2, \dots, m\}$,

$$\begin{cases} D_k = \exp(-\beta |z_{(k)} - z_{(k-1)}|), \\ R_k := \sum_{j=1}^{k-1} \exp(-\beta (z_{(k)} - z_{(j)})) = (R_{k-1} + 1) \cdot D_k, \\ S_k = S_{k-1} + R_k. \end{cases} \quad (4)$$

Preuve : On obtient immédiatement $S_1 = R_1 = 0$. Par lemme 18,

$$S = \sum_{i=1}^m \sum_{j=1}^{i-1} k_{L,\beta}(z_i, z_j) = \sum_{i=1}^m \sum_{j=1}^{i-1} \exp(-\beta |z_i - z_j|) = \sum_{i=1}^m \sum_{j=1}^{i-1} \exp(-\beta (z_{(i)} - z_{(j)}))$$

Puisque $z_{(i)} - z_{(j)} \geq 0$ pour $j < i$,

$$S_k = \sum_{i=1}^k \sum_{j=1}^{i-1} \exp(-\beta (z_{(i)} - z_{(j)})) = S_{k-1} + R_k,$$

La clé est de savoir comment mettre à jour R_k par R_{k-1} et D_k .

$$\begin{aligned} R_k &= \sum_{j=1}^{k-1} \exp(-\beta (z_{(k)} - z_{(j)})) \\ &= \sum_{j=1}^{k-1} \exp(-\beta (z_{(k)} - z_{(k-1)}) - \beta (z_{(k-1)} - z_{(j)})) \\ &= D_k \left[\sum_{j=1}^{k-1} \exp(-\beta (z_{(k-1)} - z_{(j)})) \right] \\ &= D_k \left[\sum_{j=1}^{k-2} \exp(-\beta (z_{(k-1)} - z_{(j)})) + \exp(-\beta (z_{(k-1)} - z_{(k-1)})) \right] \\ &= D_k [R_{k-1} + 1] \end{aligned}$$

On introduit les algorithmes :

Algorithme 1 : TriSSL : Triangular Sorted Sum of Laplacians

Entrée: $\beta > 0$, data $z = \{z_1, z_2, \dots, z_m\}$ avec $z_i \leq z_{i+1}$

Sortie: S

- 1: Initialiser $D = R = S = 0$
 - 2: **for** $i = 2$ à m **do**
 - 3: $D = \exp(-\beta \cdot [z_i - z_{i-1}])$
 - 4: $R = (R + 1) \cdot D$
 - 5: $S = S + R$
 - 6: **end for**
 - 7: **return** S
-

Algorithme 2 : euMMD : Efficient computation of univariate MMD². Le pseudocode de `MergeTwoAlreadySorted` est dans l'annexe

Entrée: $\beta > 0$, data $x = \{x_1, x_2, \dots, x_{n_1}\}$ et $y = \{y_1, y_2, \dots, y_{n_2}\}$

Sortie: M

```

1:  $x = \text{MergeSort}(x)$ 
2:  $y = \text{MergeSort}(y)$ 
3:  $S_1 = \text{TriSSL}(x, \beta)$ 
4:  $S_2 = \text{TriSSL}(y, \beta)$ 
5:  $S_3 = \text{MergeTwoAlreadySorted}(x, y, \beta)$ 
6:  $T_1 = S_1 / (n_1(n_1 - 1))$ 
7:  $T_2 = S_2 / (n_2(n_2 - 1))$ 
8:  $T_3 = S_3 / (n_1 n_2)$ 
9:  $M = T_1 + T_2 - T_3$ 
10: return  $M$ 

```

Proposition 21 Étant donné deux échantillons $x, y \subset \mathbb{R}$ contenant un total de n observations, l'algorithme **euMMD** calcule exactement la statistique $\text{MMD}^2(x, y)$ définie dans l'équation (1), en utilisant le noyau de Laplace avec une complexité temporelle de $O(n \log n)$ et une complexité spatiale de $O(n)$.

Preuve : La complexité des `MergeSort` est $O(n \log n)$. Les lignes 3 à 6 ont une complexité de $O(n)$ (Dans la ligne 5, nous introduisons un nouvel algorithme, qui utilise les x et y déjà triés pour réduire la complexité algorithmique de tri de $O(n \log n)$ à $O(n)$ (voir Annexe). Même si cet algorithme n'est pas utilisé, la complexité globale sera toujours contrôlée en $O(n \log n)$), et les lignes 7 à 8 ont une complexité de $O(1)$. En combinant toutes ces étapes, la complexité globale est $O(n \log n)$. La complexité spatiale du tri fusionné et de `TriSSL` est $O(n)$, ce qui signifie que la complexité spatiale de **euMMD** est également $O(n)$.

Remarque : L'algorithme **euMMD** est conçu pour offrir une efficacité remarquable grâce à son approche optimisée de tri et de calcul des statistiques. Voici une synthèse des points clés :

Une fois les données triées, la partie restante de l'algorithme s'exécute en temps linéaire $O(n)$. Cela signifie que l'étape de tri constitue le seul goulot d'étranglement de complexité $O(n \log n)$. Cependant, dans des cas particuliers, comme lorsque les données sont déjà triées ou appartiennent à des ensembles restreints (par exemple, des entiers dans un intervalle fini), il est possible d'utiliser des méthodes de tri en temps linéaire (comme le tri par comptage). Dans ces situations spécifiques, la complexité globale de l'algorithme peut être réduite à $O(n)$.

Enfin, bien que l'algorithme **euMMD** présente des similitudes conceptuelles avec les méthodes efficaces de calcul de la distance d'énergie, telles que celles proposées par [Huo and Székely \(2016\)](#), il se distingue par plusieurs innovations importantes :

- Une méthode de calcul simplifiée pour le terme mixte T_3 .
- Un cadre de mise à jour séquentielle clair, basé sur la sous-routine `TriSSL`.
- Une capacité d'adaptation au noyau de Laplace (*Laplacian kernel*), qui est difficile à intégrer dans les méthodes précédentes.

En outre, l'algorithme **euMMD** est accompagné d'une démonstration rigoureuse garantissant sa validité, renforçant ainsi sa pertinence et sa fiabilité pour des tests d'échantillons non paramétriques.

3.2 Compte p-values

Dans cette section, nous utiliserons la méthode de permutation L pour calculer la p-valeur du test MMD, et finalement, la complexité de notre algorithme est $O(Ln \log n)$. L'algorithme global est le suivant : tout d'abord, nous utilisons une méthode basée sur la médiane pour calculer le paramètre β du noyau de Laplace, puis nous calculons la statistique de test $\text{MMD}^2(x, y)$. Ensuite, nous combinons x et y pour former un ensemble z contenant n éléments. Nous appliquons un tri aléatoire à z , l'ensemble résultant est noté $\tilde{z}$, que nous divisons en deux sous-ensembles $\tilde{x}$ et $\tilde{y}$, où $\tilde{x}$ contient n_1 éléments et $\tilde{y}$ contient n_2 éléments. Ensuite, nous calculons $\text{MMD}^2(\tilde{x}, \tilde{y})$. Cette opération est répétée L fois, et nous

comptons le nombre de $\text{MMD}^2(\tilde{x}, \tilde{y})$ qui sont inférieurs ou égal à $\text{MMD}^2(x, y)$, ce nombre est noté c . Enfin, nous calculons la p-valeur :

$$p = 1 - c/(L + 1)$$

Donc si la statistique du test non permuté d'origine est grande, c sera grand et p sera petit. Dans ce cas, nous considérons que les échantillons proviennent de distributions différentes (rejet Hypothèse 0),

La base théorique de cette approche est la suivante :

Supposons que $(X_1, \dots, X_m)$ sont i.i.d. selon une distribution de probabilité P , et que, de manière indépendante, $(Y_1, \dots, Y_n)$ sont i.i.d. selon Q . Le modèle sous-jacent spécifie une famille de paires de distributions (P, Q) dans un certain espace Ω . Pour les problèmes considérés ici, Ω spécifie un modèle non paramétrique, tel que l'ensemble de toutes les paires de distributions. Soit $N = m + n$, et écrivons

$$Z = (Z_1, \dots, Z_N) = (X_1, \dots, X_m, Y_1, \dots, Y_n).$$

Soit $\hat{\Omega} = \{(P, Q) : P = Q\}$. Sous l'hypothèse $(P, Q) \in \hat{\Omega}$, la distribution jointe de $(Z_1, \dots, Z_N)$ est identique à celle de $(Z_{\pi(1)}, \dots, Z_{\pi(N)})$, où $(\pi(1), \dots, \pi(N))$ est une permutation quelconque de $\{1, \dots, N\}$. Il s'ensuit que, lorsqu'on teste une hypothèse nulle quelconque $H_0 : (P, Q) \in \Omega_0$, où $\Omega_0 \subset \hat{\Omega}$, un test exact de niveau α peut être construit à l'aide d'un test de permutation.

Pour récapituler, soit G_N l'ensemble de toutes les permutations π de $\{1, \dots, N\}$. Ensuite, étant donné une statistique de test $T_{m,n} = T_{m,n}(Z_1, \dots, Z_N)$, recalculons $T_{m,n}$ pour toutes les permutations π , c'est-à-dire calculons $T_{m,n}(Z_{\pi(1)}, \dots, Z_{\pi(N)})$ pour toutes $\pi \in G_N$.

Soit $\pi \in G_N$, et notons les valeurs ordonnées par :

$$T_{m,n}^{(1)} \leq T_{m,n}^{(2)} \leq \dots \leq T_{m,n}^{(N!)}.$$

Définissons également la distribution de permutation (la distribution de $T_{m,n}$) comme suit :

$$\hat{R}_{m,n}^T(t) = \frac{1}{N!} \sum_{\pi \in G_N} \mathbf{1}\{T_{m,n}(Z_{\pi(1)}, \dots, Z_{\pi(N)}) \leq t\}.$$

En termes simples (en tenant compte de la discrétisation), le test par permutation rejette H_0 si la statistique de test $T_{m,n}$ dépasse $T_{m,n}^{(k)}$, ou un quantile $1 - \alpha$ de cette distribution de permutation.

Ensuite, nous proposons une méthode améliorée. Tout d'abord, nous utilisons l'ensemble trié z comme point de départ, cette étape ayant une complexité de $O(n \log n)$. Ensuite, nous définissons un ensemble de référence $\omega = \{1, \dots, 1, 0, \dots, 0\}$, où n_1 éléments sont égaux à 1 et les n_2 derniers éléments sont égaux à 0. À chaque itération, nous trions ω pour obtenir $\tilde{\omega}$, tandis que l'ensemble z reste inchangé.

Ensuite, nous définissons la fonction $s(j, \tilde{\omega}) = k$, qui indique que le j -ième élément égal à 1 dans $\tilde{\omega}$ se trouve à l'indice k . De manière similaire, nous définissons $s'(j, \tilde{\omega}) = k$, qui indique que le j -ième élément égal à 0 dans $\tilde{\omega}$ se trouve à l'indice k . Ainsi, nous obtenons

$$\tilde{x} = (z_{s(1, \tilde{\omega})}, \dots, z_{s(n_1, \tilde{\omega})}), \quad \tilde{y} = (z_{s'(1, \tilde{\omega})}, \dots, z_{s'(n_2, \tilde{\omega})}).$$

De cette manière, les vecteurs rééchantillonnés continueront à être par ordre croissant, la complexité de chaque tri devient $O(n)$. La complexité totale de l'algorithme amélioré est donc $O(n \log n + Ln)$.

La méthode *euMMD* est applicable lorsque les variables sont des nombres réels. Pour des variables multidimensionnelles, ce calcul ne peut pas être effectué directement avec cet algorithme. Une approche possible consiste à prendre le produit scalaire avec un vecteur $\mathbf{u}$ situé sur la sphère unitaire de l'espace de la dimension correspondante. Pour plus de détails, veuillez vous référer à la section 4 de la référence [Bodenham et al. \(2023\)](#).

Résultat du code, voir l'annexe.

Références

- Arthur Gretton, Dino Sejdinovic, Heiko Strathmann, Sivaraman Balakrishnan, Massimiliano Pontil, Kenji Fukumizu, and Bharath K. Sriperumbudur. *Optimal kernel choice for large-scale two-sample tests*. In *Advances in Neural Information Processing Systems 25 (NIPS 2012)*, 2012.
- A. W. van der Vaart and J. A. Wellner. *Weak Convergence and Empirical Processes*. Springer, 1996.
- Bodenham, D.A., Kawahara, Y. *euMMD: efficiently computing the MMD two-sample test statistic for univariate data*. Received : 23 August 2022 / Accepted : 22 June 2023 / Published online : 27 July 2023. © The Author(s) 2023.
- C. McDiarmid. *On the Method of Bounded Differences*. In *Survey in Combinatorics*, pages 148–188. Cambridge University Press, 1989.
- Huo, X., Székely, G.J. *Fast computing for distance covariance*. *Technometrics*, **58**(4), 435–447 (2016).
- P. L. Bartlett and S. Mendelson. *Rademacher and Gaussian Complexities: Risk Bounds and Structural Results*. *Journal of Machine Learning Research*, 3 :463–482, 2002.
- Ramdas, A., Reddi, S.J., Póczos, B., et al. *On the decreasing power of kernel and distance based non-parametric hypothesis tests in high dimensions*. In : *Proceedings of the AAAI Conference on Artificial Intelligence*, (2015).
- Reed, M., and Simon, B. (1980). *Methods of Modern Mathematical Physics, Volume 1: Functional Analysis*. Academic Press, San Diego, 1980.vv
- R. Serfling. *Approximation Theorems of Mathematical Statistics*. Wiley, New York, 1980.
- Shawe-Taylor, J., Cristianini, N. *Kernel methods for pattern analysis*. Cambridge University Press, UK (2004).
- Steinwart, I., and Christmann, A. (2008). *Support Vector Machines*. Information Science and Statistics. Springer, 2008

A Algorithme de MergeTwoAlreadySorted

Algorithme 3 : MergeTwoAlreadySorted : Merging two sorted arrays in linear time

Entrée: a est un tableau trié de $m_1 \geq 1$ valeurs, $a[1] \leq a[2] \leq \dots \leq a[m_1]$, et b est un tableau trié de $m_2 \geq 1$ valeurs, $b[1] \leq b[2] \leq \dots \leq b[m_2]$.

Sortie: c est le tableau fusionné trié.

```
1:  $m = m_1 + m_2$ 
2: Initialiser  $c[1 \dots m]$  comme un nouveau tableau de  $m$  valeurs
3: Initialiser  $i = 0$ 
4: Initialiser  $j = k = 1$ 
5: repeat
6:    $i = i + 1$ 
7:   if  $a[j] \leq b[k]$  then
8:      $c[i] = a[j]$ 
9:      $j = j + 1$ 
10:  else
11:     $c[i] = b[k]$ 
12:     $k = k + 1$ 
13:  end if
14: until  $j > m_1$  ou  $k > m_2$ 
15: while  $j \leq m_1$  do
16:    $i = i + 1$ 
17:    $c[i] = a[j]$ 
18:    $j = j + 1$ 
19: end while
20: while  $k \leq m_2$  do
21:    $i = i + 1$ 
22:    $c[i] = b[k]$ 
23:    $k = k + 1$ 
24: end while
25: return  $c$ 
```

B Résultats de l'exécution du code




FIGURE 2 – Une comparaison des temps d'exécution des implémentations Python de la méthode euMMD proposée en $O(n \log n)$ sur des données univariées. Le tableau 1 montre l'accélération relative pour $n_1 = n_2 = 2000$. On peut observer que la méthode euMMD présente des avantages computationnels significatifs pour de grandes tailles d'échantillons.





FIGURE 3 – Une comparaison entre l’erreur de Type I et l’erreur de Type II. Pour chaque taux d’erreur, la moyenne est calculée sur 300 répétitions. Dans la méthode *euMMD*, 1000 permutations sont utilisées. Pour le test de l’erreur de Type I, les échantillons sont tirés de la distribution $\mathcal{N}(1, 1)$. Pour le test de l’erreur de Type II, les échantillons proviennent respectivement d’une distribution $\mathcal{N}(1, 1)$ et d’une distribution $\Gamma(1, 1)$. Les contenus des images indiquent que la méthode de test basée sur la permutation L avec la méthode *euMMD* présente de bonnes performances statistiques, en particulier pour les échantillons ayant la même moyenne et la même variance.