

Modèle linéaire en grande dimension

2024-2025

Nom : LU

Prénom : Pengcheng

Numéro étudiant : 21218540

● Titre et auteurs de l'article Titre :

Online Conformal Prediction with Decaying Step Sizes

Auteurs : Anastasios N. Angelopoulos, Rina Foygel Barber, Stephen Bates

● Que connaissiez-vous du domaine de recherche de l'article ?

Cet article explore des méthodes de prédiction conformelle en ligne. Ce domaine vise à développer des approches permettant de construire des intervalles de prédiction sans supposer de distribution spécifique pour la variable cible. Ces méthodes s'appuient sur des techniques statistiques et non paramétriques pour garantir que les intervalles de prédiction couvrent la vraie valeur avec une haute probabilité. De telles approches sont particulièrement adaptées aux scénarios où les données présentent une distribution complexe ou sont de haute dimension.

Pour la prédiction conformelle, je sais que, sous l'hypothèse d'échangeabilité des données, il est possible de calculer les p-valeurs empiriques en utilisant une « score fonction ». Dans les cours, on utilise les résidus pour mesurer le niveau de non-conformité entre la vraie valeur et l'estimateur. En ce qui concerne les calculs, on utilise la méthode de « split conformal », qui divise l'ensemble de données en un ensemble d'entraînement et un ensemble de calibration. Cela permet d'obtenir une région de prédiction $\hat{C}_\alpha$ pour Y_{n+1} qui garantit que $\mathbb{P}(Y_{n+1} \in \hat{C}_\alpha) \geq 1 - \alpha$.

Il existe également une autre méthode, appelée Jackknife, qui produit un résultat similaire avec une garantie $\mathbb{P}(Y_{n+1} \in \hat{C}'_\alpha) \geq 1 - 2\alpha$.

Il y a des problèmes de ces méthodes :

- 1 . Les violations des hypothèses peuvent entraîner une diminution du taux de couverture (par exemple, dans le cas de données non indépendantes).
- 2 . La complexité de calcul est élevée, en particulier dans les scénarios de grands ensembles de données et de données de haute dimension.
- 3 . Les méthodes de division des données peuvent entraîner une perte d'informations issues de l'entraînement.

● Sur le contenu :

- Quel problème veulent résoudre les auteurs ?

Les auteurs visent à produire des ensembles de prédiction fiables en ligne en utilisant toutes les informations d'avant avec une garantie de couverture, même dans des environnements adversariaux ou

stochastiques.

- Quel modèle est utilisé ?

Score function : $s_t : \mathcal{X} \times \mathcal{Y} \rightarrow [0, B]$, pour tout temps t . Notons que $s_t(X_t, Y_t)$ mesure la désaccord entre la prédiction du modèle de base et la vraie valeur. Modèle : $\hat{f}_t : \mathcal{X} \rightarrow \mathbb{P}$ trained online. Région de prédiction :

$$C_t(x) = \{y \in \mathcal{Y} : s_t(x, y) \leq q_t\}$$

où le q_t comme suivant :

$$q_{t+1} = q_t + \eta_t (\mathbf{1}_{Y_t \notin C_t(X_t)} - \alpha).$$

q_t est mise à jour à chaque pas. Si η_t est une constante, le résultat est mauvais car la probabilité de couverture de l'intervalle peut subir de grandes oscillations. On choisit $\eta_t \propto t^{-1/2-\varepsilon}$, $\varepsilon \in (0, 1/2)$. Notons $\text{Coverage}_t(q) = \mathbb{P}_P(s_t(X, Y) \leq q \mid s_t)$.

Caractéristiques clés du modèle :

— Dans des environnements adversariaux :

Soit $(X_1, Y_1), (X_2, Y_2), \dots$ une suite arbitraire de points de données, et soit $s_t : \mathcal{X} \times \mathcal{Y} \rightarrow [0, B]$ une fonction quelconque. Soit η_t une suite positive quelconque, et fixons un seuil initial $q_1 \in [0, B]$. Alors, la prédiction conforme en ligne satisfait

$$\left| \frac{1}{T} \sum_{t=1}^T \mathbf{1}_{Y_t \notin C_t(X_t)} - (1 - \alpha) \right| \leq \frac{B + \max_{1 \leq t \leq T} \eta_t}{T} \cdot \|\Delta_{1:T}\|_1$$

pour tout $T \geq 1$, où la suite Δ est définie par les valeurs suivantes :

$$\Delta_1 = \eta_1^{-1}, \quad \text{et} \quad \Delta_t = \eta_t^{-1} - \eta_{t-1}^{-1} \quad \text{pour tout } t \geq 2.$$

$$\|\Delta_{1:T}\|_1 = |\eta_1^{-1}| + \sum_{t=2}^T |\eta_t^{-1} - \eta_{t-1}^{-1}|$$

— Dans des environnements I.I.D. :

Notons $(X_1, Y_1), (X_2, Y_2), \dots$ des échantillons i.i.d de distribution P sur $\mathcal{X} \times \mathcal{Y}$, $s_t \rightarrow s$, pour $s : \mathcal{X} \times \mathcal{Y} \rightarrow [0, B]$ continue, $\sum_{t=1}^{\infty} \eta_t = \infty$, $\sum_{t=1}^{\infty} \eta_t^2 < \infty$, alors

$$\lim_{t \rightarrow \infty} \mathbb{P}(Y_t \in C_t(X_t)) = 1 - \alpha.$$

- Quelle est l'application utilisée ? (si présente)

Dans **section 4**, les auteurs valident les performances de la méthode **prédiction conforme en ligne** avec des pas constants et des pas décroissants, en la comparant à une méthode "idéale" (*oracle method*). Les expériences portent sur deux ensembles de données issus de domaines différents :

Expérimentation 1 : Jeu de données Elec2

- **Contexte du jeu de données** : Cet ensemble contient des séries temporelles de la demande en électricité en Nouvelle-Galles du Sud, Australie (45312 mesures horaires).
- **Mise en œuvre** :
 - Les données historiques sont utilisées comme caractéristiques (X_t) pour prédire la demande actuelle (Y_t) basée sur une moyenne mobile décalée d'un jour.
 - La fonction de score conforme est définie par l'erreur résiduelle $|Y_t - \hat{Y}_t|$.
- **Résultats** :
 - La méthode avec des **pas constants** présente une plus grande fluctuation dans les seuils prédictifs q_t et dans la couverture instantanée.
 - La méthode avec des **pas décroissants** stabilise la couverture au niveau cible $1 - \alpha$ et réduit la variabilité des ensembles prédictifs.

Expérience 2 : Jeu de données ImageNet

- **Contexte du jeu de données** : Cet ensemble utilise 50000 images de la validation d'ImageNet 2012, simulées comme une série temporelle.
- **Mise en œuvre** :
 - Les scores softmax issus d'un modèle ResNet-152 sont utilisés comme fonction de score conforme.
 - 45000 images sont utilisées comme série temporelle et 5000 comme jeu d'évaluation.
- **Résultats** :
 - La méthode avec des **pas décroissants** offre une couverture instantanée et des seuils q_t plus stables.
 - La méthode avec des **pas constants** présente une variabilité importante, avec des ensembles prédictifs souvent trop larges ou trop étroits.

Ces résultats montrent que les **pas décroissants** sont mieux adaptés aux systèmes dynamiques nécessitant des prédictions en ligne, tout en minimisant l'instabilité causée par des pas inadéquats.

● Quel est le take-home message du papier ?

Les tailles de pas décroissantes permettent une convergence des ensembles de prédiction dans des environnements I.I.D. tout en maintenant une garantie de couverture dans des environnements adversariaux. Le modèle proposé représente un progrès significatif dans la prédiction conforme en ligne, combinant efficacité, robustesse et adaptabilité pour une large gamme d'applications.

● Quelles sont les principales hypothèses de l'article ?

1. Les données peuvent être soit adversariales soit I.I.D.
2. Le score conforme est borné et suit une structure cohérente avec les données.
3. La distribution sous-jacente peut permettre une convergence des scores dans des contextes stochastiques.

● Si vous deviez juger cet article, quels seraient vos critiques sur son contenu ?

L'article ne fournit pas le choix optimal des certains hyperparamètres, tels que la taille des pas. Le choix de s_t a une influence déterminante sur la convergence de la méthode.

● Quels sont les problèmes qui restent à résoudre ?

1. L'analyse théorique actuelle se concentre principalement sur les séquences indépendantes et identiquement distribuées (I.I.D.) et les séquences adversariales. Étendre cette analyse à des scénarios plus complexes (comme les séries temporelles stationnaires ou à évolution lente) reste un défi à relever.

2. Les garanties de couverture proposées dépendent de la qualité des fonctions de score. La manière de sélectionner les modèles et fonctions de score appropriés, en particulier dans des contextes où les distributions de données évoluent, nécessite encore des investigations.