

ONLINE CONFORMAL PREDICTION WITH DECAYING STEP SIZES

Modèle linéaire et grande dimension

9 janvier 2025

Lu Pengcheng – Zhang Chen

1 Motivation Pratique

2 Modèle

3 Théorème

4 Simulation

5 Take-home Message

Motivation Pratique

Motivation Pratique

Le problème de la prédiction incertaine en ligne est utile dans des domaines

- la prévision de séries temporelles
- la finance
- la médecine
- la robotique

L'objectif est de construire des ensembles prédictifs robustes qui contiennent la valeur réelle avec un certain niveau de confiance.

Modèle

Modèle

Score function : $s_t : \mathcal{X} \times \mathcal{Y} \rightarrow [0, B]$, pour tout temps t .

Région de prédiction :

$$C_t(x) = \{y \in \mathcal{Y} : s_t(x, y) \leq q_t\}$$

où le q_t comme suivant :

$$q_{t+1} = q_t + \eta_t (1_{Y_t \notin C_t(X_t)} - \alpha) .$$

q_t est mise à jour à chaque pas. Notons

$$\text{Coverage}_t(q) = \mathbb{P}_P(s_t(X, Y) \leq q \mid s_t)$$

Cadres d'étude

- **Cadre 1 (Contexte adversarial)** $(X_1, Y_1), (X_2, Y_2), \dots$ soient une séquence arbitraire d'éléments dans $\mathcal{X} \times \mathcal{Y}$, et que $s_1, s_2, \dots$ soient une séquence arbitraire de fonctions de $\mathcal{X} \times \mathcal{Y}$ vers $[0, B]$.
- **Cadre 2 (Contexte I.I.D.)** $(X_t, Y_t) \stackrel{\text{i.i.d.}}{\sim} P$ pour une certaine distribution P , et que le choix de la fonction $s_t : \mathcal{X} \times \mathcal{Y} \rightarrow [0, B]$ dépende uniquement de $\{(X_r, Y_r)\}_{r < t}$, pour chaque t .

Théorème

Borne supérieure pour ensemble adversarial

Théorème 2

Soit $(X_1, Y_1), (X_2, Y_2), \dots$ une séquence arbitraire de points de données, et soit $s_t : \mathcal{X} \times \mathcal{Y} \rightarrow [0, B]$ une fonction quelconque. Soit η_t une séquence positive arbitraire, et fixons un seuil initial $q_1 \in [0, B]$.

Alors, la prédiction conforme en ligne satisfait

$$\left| \frac{1}{T} \sum_{t=1}^T 1_{Y_t \in C_t(X_t)} - (1 - \alpha) \right| \leq \frac{B + \max_{1 \leq t \leq T} \eta_t}{T} \cdot \|\Delta_{1:T}\|_1,$$

pour tout $T \geq 1$, où la séquence Δ est définie avec les valeurs

$$\Delta_1 = \eta_1^{-1}, \quad \Delta_t = \eta_t^{-1} - \eta_{t-1}^{-1} \quad \text{pour tout } t \geq 2.$$

Lemme

Soit $(X_1, Y_1), (X_2, Y_2), \dots$ une séquence arbitraire de points de données, et soit $s_t : \mathcal{X} \times \mathcal{Y} \rightarrow [0, B]$ une fonction quelconque. Soit η_t une séquence non négative arbitraire, et fixons un seuil initial $q_1 \in [0, B]$. Alors, la prédiction conforme en ligne satisfait

$$-\alpha M_{t-1} \leq q_t \leq B + (1 - \alpha)M_{t-1} \quad \text{pour tout } t \geq 1,$$

où $M_0 = 0$, et $M_t = \max_{1 \leq r \leq t} \eta_r$ pour chaque $t \geq 1$.

Éléments de preuve II

Par définition de Δ , nous avons $\eta_t^{-1} = \sum_{r=1}^t \Delta_r$ pour tout $t \geq 1$.
Nous calculons alors

$$\begin{aligned}
 \left| \frac{1}{T} \sum_{t=1}^T 1_{Y_t \in C_t(X_t)} - (1 - \alpha) \right| &= \left| \frac{1}{T} \sum_{t=1}^T 1_{Y_t \notin C_t(X_t)} - \alpha \right| \\
 &= \left| \frac{1}{T} \sum_{t=1}^T \left(\sum_{r=1}^t \Delta_r \right) \cdot \eta_t (1_{Y_t \notin C_t(X_t)} - \alpha) \right| \\
 &= \left| \frac{1}{T} \sum_{r=1}^T \Delta_r \left(\sum_{t=r}^T \eta_t (1_{Y_t \notin C_t(X_t)} - \alpha) \right) \right| \\
 &= \left| \frac{1}{T} \sum_{r=1}^T \Delta_r \cdot (q_{T+1} - q_r) \right|
 \end{aligned}$$

Éléments de preuve III

$$\begin{aligned} &\leq \frac{1}{T} \sum_{r=1}^T |\Delta_r| \cdot \max_{1 \leq r \leq T} |q_{T+1} - q_r| \\ &\leq \frac{1}{T} \|\Delta_{1:T}\|_1 \cdot \left(B + \max_{1 \leq t \leq T} \eta_t \right), \end{aligned}$$

où la dernière étape est vraie car q_r et q_{T+1} sont bornés selon le Lemme.

Cas de pas constante

Proposition 3

Soit $(X_t, Y_t) \stackrel{\text{i.i.d.}}{\sim} P$ pour une certaine distribution P , et supposons que les fonctions de score $s_t : \mathcal{X} \times \mathcal{Y} \rightarrow [0, B]$ sont entraînées en ligne. Soit $\eta_t \equiv \eta$ pour une taille de pas constante positive $\eta > 0$. Alors, la prédiction conforme en ligne satisfait

$$\liminf_{t \rightarrow \infty} \text{Coverage}_t(q_t) = 0, \quad \limsup_{t \rightarrow \infty} \text{Coverage}_t(q_t) = 1,$$

presque sûrement.

Preuve I

Construction de U_t : Pour chaque instant $t \geq 1$, définissons une variable U_t par :

$$U_t \sim \begin{cases} \text{Uniform}[0, \text{Coverage}_t(q_t)] & \text{si } Y_t \in C_t(X_t), \\ \text{Uniform}[\text{Coverage}_t(q_t), 1] & \text{si } Y_t \notin C_t(X_t). \end{cases}$$

En utilisant la définition de la probabilité de couverture, on montre que les $U_t \sim \text{Uniform}[0, 1]$, I.I.D.

Preuve II

Définition des événements A_i : Soit

$A_i = \{U_t > 1 - \epsilon \mid (i-1)N < t \leq iN\}$. Par le lemme de Borel-Cantelli, on montre que $\mathbb{P}(\sum_{i \geq 1} 1_{A_i} = \infty) = 1$, ce qui implique :

Si A_i existe, alors $\max_{(i-1)N < t \leq iN} \text{Coverage}_t(q_t) > 1 - \epsilon$

$$\limsup_{t \rightarrow \infty} \text{Coverage}_t(q_t) = 1$$

Théorème 4

Théorème 4

Soit $(X_t, Y_t) \stackrel{\text{i.i.d.}}{\sim} P$ pour une distribution P , et supposons que les fonctions de score s_t sont entraînées en ligne. Supposons que la séquence de pas η_t est fixe, non négative, et satisfait :

$$\sum_{t=1}^{\infty} \eta_t = \infty, \quad \sum_{t=1}^{\infty} \eta_t^2 < \infty.$$

Soit $s : \mathcal{X} \times \mathcal{Y} \rightarrow [0, B]$ une fonction de score fixée, et supposons que q^* est unique comme défini ci-dessous :

$$\text{Coverage}(q) < 1 - \alpha \quad \text{pour tout } q < q^*,$$

$$\text{Coverage}(q) > 1 - \alpha \quad \text{pour tout } q > q^*.$$

Alors la prédiction conforme en ligne satisfait presque sûrement l'énoncé suivant :

$$\text{Si } s_t \xrightarrow{d} s, \text{ alors } q_t \rightarrow q^*.$$

Théorème 4

martingale

Conditions :

1. **Dépendance** : La valeur de X_t dépend uniquement des informations passées.
2. **Finitude** : Pour tout t , on a :

$$\mathbb{E}[|X_t|] < \infty.$$

3. **Équité** : Pour tout $t \geq 0$, on a :

$$\mathbb{E}[X_{t+1} \mid \mathcal{F}_t] = X_t.$$

Théorème 4

martingale

$$Z_t = \sum_{r=1}^t \eta_r (1_{Y_r \in C_r(X_r)} - \text{Coverage}_r(q_r)) .$$

On doit prouver que la séquence Z_t converge presque partout quand $t \rightarrow \infty$.

Théorème 4

martingale

$$Z_t = \sum_{r=1}^t \eta_r (1_{Y_r \in C_r(X_r)} - \text{Coverage}_r(q_r)) .$$

On doit prouver que la séquence converge presque partout.

$$Z_{t+1} - Z_t = \eta_{t+1} (1_{Y_{t+1} \in C_{t+1}(X_{t+1})} - \text{Coverage}_{t+1}(q_{t+1}))$$

$$\mathbb{E}[Z_{t+1} - Z_t] = \mathbb{E} [\eta_{t+1} (1_{Y_{t+1} \in C_{t+1}(X_{t+1})} - \text{Coverage}_{t+1}(q_{t+1}))] = 0 .$$

Ainsi, $\mathbb{E}[Z_{t+1} \mid \mathcal{F}_t] = Z_t$.

Théorème 4

preuve

Étant donné que la fonction $q \mapsto \text{Coverage}(q)$ est monotone et que les définitions de Z_t et η_t sont données. Avec un T , pour tout $t \geq T$ nous pouvons obtenir les inégalités suivantes :

$$\sup_{t' \geq t \geq T} |Z_{t'} - Z_{t-1}| \leq \frac{\epsilon}{3}$$

$$\eta_t \leq \frac{\epsilon}{3}$$

$$\text{Coverage}_t(q^* - \frac{\epsilon}{3}) \leq 1 - \alpha - \delta$$

$$\text{Coverage}_t(q^* + \frac{\epsilon}{3}) \geq 1 - \alpha + \delta$$

Théorème 4

cas 1

Quand $q_t < q^* - \frac{\epsilon}{3}$ for all $t \geq T$.

On a :

$$q^* - \frac{\epsilon}{3} - q_T \geq \sup_{t > T} q_t - q_T \quad (1)$$

$$= \sup_{t > T} \sum_{r=T}^{t-1} \eta_r (1_{Y_r \notin C_r(X_r)} - \alpha) \quad (2)$$

$$\geq \sup_{t > T} \sum_{r=T}^{t-1} \eta_r ((1 - \alpha) - \text{Coverage}_r(q_r)) - \frac{\epsilon}{3} \quad (3)$$

$$\geq \sup_{t > T} \left\{ \sum_{r=T}^{t-1} \eta_r \cdot \delta \right\} - \frac{\epsilon}{3}. \quad (4)$$

Théorème 4

cas 2

pour certains $t' \geq t'' \geq T$, $q_{t''} \geq q^* - \epsilon/3$ et $q_{t'} < q^* - \epsilon$.

On a :

$$-\frac{2\epsilon}{3} > q_{t'} - q_{t''} = \sum_{r=t''}^{t'-1} \eta_r (1_{Y_r \notin C_r(X_r)} - \alpha), \quad (5)$$

$$\geq \left[\sum_{r=t''}^{t'-1} \eta_r ((1 - \alpha) - \text{Coverage}_r(q_r)) \right] - \frac{\epsilon}{3}, \quad (6)$$

$$\geq -\eta_{t''} + \left[\sum_{r=t''+1}^{t'-1} \eta_r ((1 - \alpha) - \text{Coverage}_r(q_r)) \right] - \frac{\epsilon}{3}, \quad (7)$$

$$\geq -\eta_{t''} - \frac{\epsilon}{3}. \quad (8)$$

Simulation

Simulation

Résultats de expérimentation :




Figure 1. **Elec2 results.** From left to right, the panels display the following (over all times t): first, the value of the threshold q_t ; second, the instantaneous coverage $\text{Coverage}_t(q_t)$; third, the long-run coverage $\frac{1}{t} \sum_{r=1}^t \mathbb{1}_{Y_r \in \mathcal{C}_r(X_r)}$; and fourth, the rolling coverage, averaged over a rolling window of 1000 time points.




Figure 2. **Imagenet results.** Same details as for Figure 1.

q_t , $\text{Coverage}(q_t)$, Couverture à long terme, Couverture glissante

Take-home Message

Take-home Message

Point clé :

$$q_{t+1} = q_t + \eta_t (1_{Y_t \notin C_t(X_t)} - \alpha)$$

où

$$\eta_t \propto t^{-1/2-\epsilon}.$$

Dans cet article, une nouvelle méthode de construction des intervalles de prédiction est proposée et justifiée. Cette approche permet de prendre en compte à la fois les données I.I.D. et les données adversaires.

Take-home Message

problèmes qui restent à résoudre :

(1) :Le preuve de $\eta_t \propto t^{-1/2-\epsilon}$

(2) :Les données I.I.D. sont rares dans la réalité

(3) :Améliorée grâce à des algorithmes d'apprentissage en ligne plus avancés.