

Raport

Pengcheng Lu

November 2024

1 Prétraitement des données

En examinant les valeurs manquantes des données, nous avons constaté que dans le fichier `X_train`, les colonnes `'load_forecast'` et `'predicted_spot_price'` contiennent un grand nombre de valeurs manquantes, tandis que dans le fichier `X_test`, la colonne `'predicted_spot_price'` présente également certaines valeurs manquantes. Nous avons effectué un traitement des valeurs aberrantes sur les données de `Y_train`, en appliquant la règle des 3σ . Les valeurs aberrantes ont été remplacées par la moyenne des deux valeurs adjacentes.

1.1 load_forecast

Pour la colonne `load_forecast`, en observant les graphiques et en appliquant la méthode de différenciation par pas de K , nous avons identifié une certaine **périodicité** dans cette colonne. Nous avons défini chaque groupe de 168 données comme un cycle et comblé les valeurs manquantes en utilisant la moyenne des cinq dernières valeurs précédentes aux indices $168 \times i, i = 1, 2, 3, 4, 5$. Afin de détecter la tendance dans les données, nous avons effectué une analyse de séries chronologiques de la colonne `'load_forecast'` après remplissage, en utilisant le logiciel **SPSS**. Sur la base du coefficient de détermination R ajusté, nous avons choisi le modèle $ARIMA(5,1,1)$ pour ajuster les données, et les valeurs manquantes initiales ont été complétées par les valeurs ajustées par le modèle $ARIMA$ lors d'un second remplissage. Dans toutes les opérations ultérieures, nous utiliserons ces valeurs issues du second remplissage.

Pour les quatre colonnes de données liées au vent et à l'énergie solaire, l'observation graphique a révélé une forte variabilité aléatoire, et étant donné le faible nombre de valeurs manquantes, nous avons choisi de les combler par la **moyenne des valeurs** aux indices situés 336 positions avant et 336 positions après les valeurs manquantes. Pour les données manquantes des autres colonnes (à l'exception de ces cinq colonnes et de la colonne `predicted_spot_price`), nous avons opté pour une **interpolation linéaire**.

1.2 predicted_spot_price

Étant donné la quantité importante de données manquantes, nous avons choisi de **combiner** `X_train` et `X_test` pour entraîner le modèle et remplir les valeurs manquantes de manière intégrée. Tout d'abord, les lignes contenant des valeurs manquantes ont été séparées en tant qu'ensemble de prédiction et exclues de l'ensemble d'entraînement. Dans l'ensemble d'entraînement, toutes les autres colonnes ont été utilisées comme caractéristiques, et nous avons utilisé les méthodes de régression linéaire, Lasso, Ridge et AdaBoost pour modéliser et prédire les valeurs manquantes.

En ce qui concerne le choix des paramètres du modèle, nous avons utilisé les fonctions fournies par la bibliothèque **SKlearn** pour une sélection automatique des paramètres. Ensuite, nous avons appliqué une **validation croisée** en 7 plis, divisant l'ensemble d'entraînement en 7 parties, en sélectionnant chaque fois une partie comme ensemble de test et les autres comme ensemble d'entraînement. Chaque modèle a été soumis à cette validation croisée, et la moyenne des **MSE** obtenus a été utilisée comme poids pour chaque prédiction. Enfin, la moyenne pondérée des valeurs prédites a été utilisée pour combler les parties manquantes.

2 modèle

Étant donné la dimension temporelle des données, nous avons choisi d'ajouter le temps comme caractéristique pour améliorer l'ajustement et les prédictions. Nous avons opté pour le modèle de **forêt**

aléatoire comme modèle principal. Grâce à l'utilisation de **Randomsearch**, nous avons optimisé plusieurs hyperparamètres, notamment : le nombre d'arbres, la profondeur des arbres, le nombre minimum d'échantillons nécessaires pour diviser un nœud (avec des valeurs faibles pour capturer des distinctions fines), le nombre minimum d'échantillons requis dans chaque feuille pour équilibrer la complexité, le nombre de caractéristiques à considérer pour déterminer la meilleure séparation, l'utilisation ou non de l'échantillonnage bootstrap, et la fraction d'échantillons utilisée si 'bootstrap=True' (variant entre 10 % et 90 %). Cette gamme de paramètres a été affinée à partir de multiples recherches aléatoires des configurations optimales.

Nous avons également utilisé une **méthode d'optimisation bayésienne** pour affiner les paramètres, ce qui nous a permis de déterminer un ensemble optimal de paramètres via validation croisée.

Après plusieurs recherches aléatoires, nous avons établi 9 modèles et exporté leurs valeurs prédites. Un dixième modèle a été construit en utilisant les paramètres obtenus par optimisation bayésienne, et les prédictions de ce modèle ont également été exportées. Par la suite, nous avons été informés qu'il y avait plus de prédictions positives que négatives. En conséquence, nous avons appliqué un système de vote sur les prédictions de ces 10 modèles. Pour une valeur prédite à un indice de temps donné, nous avons d'abord déterminé sa nature positive ou négative : si 8 modèles sur 10 prédisaient une valeur négative, nous l'avons considérée comme négative, et la valeur a été fixée à la moyenne des valeurs absolues des 10 modèles.

3 Classement et résultats

Sur Public academic leaderboard, ranking : 22, note : 0.5666

4 Les obstacles rencontrés et réalisations

4.1 obstacles

1. Lors du traitement des données, si nous ajustons directement un modèle ARIMA sur la colonne Load.forecast contenant des valeurs manquantes, les prédictions du modèle pour les valeurs manquantes prennent la forme d'une ligne droite. Cependant, si nous réalisons un nouvel ajustement ARIMA après chaque remplissage individuel d'une valeur manquante, le calcul devient très lourd, et le problème persiste malgré cela.

2. Lors du traitement de la colonne predicted_spot_price dans le fichier X_train, l'importante quantité de valeurs manquantes a conduit à des prédictions peu précises des valeurs manquantes.

3. Lors de la création de la matrice de corrélation, nous avons constaté que presque toutes les colonnes de X_train avaient une faible corrélation avec la variable cible Y, rendant difficile l'application de techniques d'ingénierie des caractéristiques pour réduire la dimensionnalité.

4. Lors de la sélection des paramètres optimaux pour le modèle de forêt aléatoire avec optimisation bayésienne, la plupart des paramètres optimaux ne se trouvaient pas aux limites de l'espace de recherche, à l'exception de quelques-uns. L'utilisation de cet ensemble de paramètres a entraîné un problème de sur-apprentissage très prononcé.

4.2 réalisations

1. La seconde étape de remplissage de la colonne Load.forecast a permis de préserver la périodicité des données tout en capturant au mieux la tendance sous-jacente.

2. L'utilisation des ensembles de paramètres obtenus par plusieurs recherches aléatoires pour l'ajustement et le vote des modèles a permis de réduire l'impact du surapprentissage.